





MACHINE
LEARNING



LOGISTIC REGRESSION, K-NEAREST NEIGHBOR, NAÏVE BAYES, DECISION TREE

KELOMPOK 1



Kelompok 1

■	Aulia Vika Rahman	(2208107010001)
■	Shofia Nurul Huda	(2208107010015)
■	M. Ihsan Rizqullah Adfa	(2208107010029)
■	Nashed Bayazid Ali	(2208107010049)
■	Muhammad Raza Adzani	(2208107010066)
■	T. Farhan Syah	(2208107010090)



PENDAHULUAN



LATAR BELAKANG:

Kesehatan maternal adalah indikator penting kesehatan global, dengan 810 kematian ibu per hari yang sebagian besar dapat dicegah. Machine learning memungkinkan deteksi dini kehamilan berisiko tinggi dengan menganalisis parameter kesehatan dan demografis secara simultan, mendukung pengambilan keputusan klinis yang lebih cepat dan akurat.

TUJUAN PROYEK:

- Memprediksi risiko kesehatan maternal dengan model klasifikasi
- Mengidentifikasi faktor-faktor penentu risiko
- Membandingkan performa KNN, Decision Tree, Logistic Regression, dan Naive Bayes
- Menentukan model terbaik untuk sistem pendukung keputusan klinis

DATASET:

Sumber & Deskripsi:

- Maternal Health Risk Data Set
- Sumber: UCI Machine Learning Repository
- Jenis Data: Data kesehatan ibu hamil dan klasifikasi risiko kehamilan
- Jumlah Sampel: 1.014 entri
- Jumlah Fitur: 6 fitur numerik + 1 label (RiskLevel)
- Format: CSV

Tujuan Dataset:

- Memprediksi tingkat risiko kesehatan maternal berdasarkan parameter fisiologis dan demografis
- Menjadi referensi dalam pengembangan sistem pendukung keputusan klinis berbasis machine learning
- Digunakan dalam berbagai studi ilmiah terkait kesehatan maternal



EKSPLORASI DATA DAN PRA-PEMROSESAN

STATISTIK DESKRIPTIF AWAL

- tidak ada missing values.
- Banyak duplikat (direduksi dari 1014 → 452 data).
- Terdapat anomali: nilai HeartRate = 7, diganti dengan modus = 70.
- RiskLevel di-encode sebagai label ordinal (low, mid, high).

OUTLIER

- Deteksi dengan boxplot.
- Outlier ditemukan pada: BS (Blood Sugar), Age, BodyTemp.
- Tidak dihapus karena dianggap valid (representasi kasus ekstrem).

STATISTIK DESKRIPTIF AWAL

- Distribusi kelas: Low Risk paling dominan.
- Risiko tinggi meningkat signifikan pada usia >35 dan gula darah >8 mmol/L.
- Tekanan darah tinggi dan suhu tubuh tinggi berkorelasi dengan risiko tinggi.
- HeartRate normal terdistribusi, tidak banyak pengaruh pada kelas risiko.

KORELASI ANTAR FITUR

- Korelasi positif paling kuat hanya pada fitur BS.
- Korelasi ditampilkan dengan heatmap.

KORELASI ANTAR FITUR

- Skewness dikoreksi dengan log dan Box-Cox transformasi.
- Fitur yang diubah: BS, Age.

IMPLEMENTASI MODEL

EMPAT MODEL MACHINE LEARNING DITERAPKAN UNTUK KLASIFIKASI RISIKO KEHAMILAN:

- K-Nearest Neighbors (KNN)
- Decision Tree
- Logistic Regression
- Naive Bayes

HYPERPARAMETER TUNING

KNN:

- Dicoba nilai $K = 1-19$
- K terbaik = 16 berdasarkan error terkecil

Decision Tree:

- Grid Search untuk: criterion, max_depth, min_samples_leaf, dll.
- Parameter terbaik: entropy, max_depth=20, splitter=random

Logistic Regression:

- Digunakan Multinomial Logistic Regression
- Grid Search untuk $C = [0.01, 0.1, 1, 10, 100]$ dan penalty = 11/12


Naive Bayes:

- Model: Gaussian Naive Bayes
- Tidak perlu banyak parameter tuning





PERBANDINGAN MODEL



MODEL 1

K Nearest Neighbors

```
K Nearest Neighbors K=16
```


```
[[62  6  2]
 [20  6  6]
 [ 9  3 22]]
```

	precision	recall	f1-score	support
0	0.68	0.89	0.77	70
1	0.40	0.19	0.26	32
2	0.73	0.65	0.69	34
accuracy			0.66	136
macro avg	0.60	0.57	0.57	136
weighted avg	0.63	0.66	0.63	136

- Akurasi: 66%
- Kelebihan: Sangat baik mengklasifikasikan risiko rendah (kelas 0).
- Kekurangan: Sangat lemah pada kelas risiko sedang (kelas 1), recall hanya 19%.



PERBANDINGAN MODEL



MODEL 2


Decision Tree

Decision Tree Performance on Test Set				
[[65 3 2] [19 8 5] [5 8 21]]				
	precision	recall	f1-score	support
0	0.73	0.93	0.82	70
1	0.42	0.25	0.31	32
2	0.75	0.62	0.68	34
accuracy			0.69	136
macro avg	0.63	0.60	0.60	136
weighted avg	0.66	0.69	0.66	136

- Akurasi: 69%
- Kelebihan: Baik dalam mengklasifikasikan risiko tinggi (kelas 2), recall 62%.
- Kekurangan: Precision kelas 1 masih rendah (42%).



PERBANDINGAN MODEL



MODEL 3

Logistic Regression

Logistic Regression Performance on Test Set


```
[[67  1  2]
 [21  6  5]
 [ 9  1 24]]
```

	precision	recall	f1-score	support
0	0.69	0.96	0.80	70
1	0.75	0.19	0.30	32
2	0.77	0.71	0.74	34
accuracy			0.71	136
macro avg	0.74	0.62	0.61	136
weighted avg	0.73	0.71	0.67	136

- Akurasi: 71% (tertinggi)
- Kelebihan: Performa seimbang di semua kelas; recall kelas 0 sangat tinggi (96%).
- Kekurangan: Recall kelas 1 masih rendah (19%), meski precision-nya tinggi (75%).



PERBANDINGAN MODEL



MODEL 4

Naive Bayes

Naive Bayes Performance on Test Set


```
[[64 6 0]
 [25 4 3]
 [ 4 7 23]]
```

	precision	recall	f1-score	support
0	0.69	0.91	0.79	70
1	0.24	0.12	0.16	32
2	0.88	0.68	0.77	34
accuracy			0.67	136
macro avg	0.60	0.57	0.57	136
weighted avg	0.63	0.67	0.63	136

- Akurasi: 67%
- Kelebihan: Precision sangat tinggi untuk kelas 2 (88%).
- Kekurangan: Sangat buruk untuk kelas 1, recall hanya 12%.




PERBANDINGAN MODEL



MODEL	AKURASI	KELAS 0 (Rendah)	KELAS 1 (Sedang)	KELAS 2 (Tinggi)
KNN	66%	(recall 89%)	(recall 19%)	(recall 65%)
Decision Tree	69%	(recall 93%)	(recall 31%)	(recall 62%)
Logistic Regression	71%	(recall 96%)	(recall 19%)	(recall 71%)
Naive Bayes	67%	(recall 91%)	(recall 12%)	(recall 68%)



KESIMPULAN



Kesimpulan:

1. Logistic Regression menunjukkan performa terbaik secara keseluruhan (akurasi 71%) dan seimbang untuk semua kelas risiko.
2. Semua model mengalami kesulitan mengklasifikasikan risiko sedang (kelas 1) – ini menunjukkan perlunya fitur yang lebih membedakan.
3. Untuk aplikasi klinis:
 - Gunakan Naive Bayes bila fokus utama adalah mengidentifikasi risiko tinggi secara akurat.
 - Gunakan Logistic Regression bila dibutuhkan keseimbangan antar semua risiko.

Rekomendasi:

1. Tambahkan data khususnya untuk kelas risiko sedang.
2. Lakukan feature engineering untuk menemukan fitur pembeda yang lebih baik.
3. Coba pendekatan ensemble (misalnya Random Forest atau voting classifier).
4. Optimasi lanjutan seperti tuning hyperparameter dan class balancing disarankan.



TERIMA KASIH

KELOMPOK 1

MACHINE
LEARNING